

Исследование методов обучения с подкреплением для пошаговых игр со случайностью

Студент: Дай Ганьилэ

Научный руководитель: Оганесян Павел Артурович

Промежуточная аттестация по выпускной квалификационной работе

Шэньчжэнь, 2026

Структура доклада

- ❶ Введение: актуальность, цель и задачи работы.
- ❷ Теоретическая основа: RL, марковские игры, маски допустимых действий, PPO.
- ❸ Программная реализация: Gymnasium, Ray RLlib, PyTorch, shared policy.
- ❹ Эксперимент Tic-Tac-Toe: функция награды, reward sweep, результаты.

Фокус промежуточного доклада: показать, что первые четыре главы образуют законченную экспериментальную схему: от постановки задачи до проверочного эксперимента.

Актуальность, цель и задачи

Актуальность. Пошаговые игры являются удобной моделью последовательного принятия решений. Случайность, несколько игроков и ограничения допустимых действий делают такие задачи естественной областью применения обучения с подкреплением.

Цель работы. Построить и экспериментально исследовать модели обучения с подкреплением для пошаговых игр со случайностью на примере Tic-Tac-Toe и Einstein Würfelt Nicht!.

Основные задачи первых глав:

- 1 описать RL-постановку для пошаговых игр;
- 2 реализовать многоагентные среды с масками допустимых действий;
- 3 настроить обучение PPO в shared-policy схеме;
- 4 проверить схему на Tic-Tac-Toe и исследовать влияние награды за ничью.

Tic-Tac-Toe

- простая детерминированная игра;
- полная информация;
- малое число состояний;
- существует точный алгоритм minimax .

Роль в работе: проверка корректности среды, награды, маски действий и процедуры обучения.

Einstein Würfelt Nicht!

- игра с броском кубика;
- изменяемая начальная конфигурация;
- сложный набор допустимых ходов;
- более содержательный объект для RL.

Роль в работе: следующий этап после проверки методики на Tic-Tac-Toe.

Формализация задачи

Марковский процесс принятия решений

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma).$$

Агент максимизирует ожидаемую дисконтированную награду:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}.$$

Особенность пошаговой игры: на каждом ходе активен один игрок, но результат его действия зависит от стратегии противника.

Двухигровая нулевая марковская игра

$$\mathcal{G} = (\mathcal{S}, \mathcal{A}_1, \mathcal{A}_2, P, R_1, R_2, \gamma).$$

В нулевой сумме:

$$R_1(s, a_1, a_2) = -R_2(s, a_1, a_2).$$

Маска допустимых действий

Во многих игровых состояниях не все действия допустимы. Например, в Тис-Тас-Тое нельзя поставить знак в занятую клетку.

Маска допустимых действий:

$$m(a \mid s) = \begin{cases} 1, & a \in \mathcal{A}_{\text{legal}}(s), \\ 0, & a \notin \mathcal{A}_{\text{legal}}(s). \end{cases}$$

После применения маски к логитам политики:

$$z'_\theta(s, a) = z_\theta(s, a) + \begin{cases} 0, & a \in \mathcal{A}_{\text{legal}}(s), \\ -10^9, & a \notin \mathcal{A}_{\text{legal}}(s). \end{cases}$$

Практический эффект: модель не тратит rollout на заведомо невозможные ходы.

PPO ограничивает изменение политики между последовательными обновлениями.

Clipped surrogate objective:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right].$$

Actor

- получает наблюдение и маску;
- формирует logits действий;
- выбирает ход текущего игрока.

Critic

- оценивает ценность состояния;
- стабилизирует policy gradient;
- используется в actor-critic архитектуре.

Программная реализация

Используемые инструменты:

- Python — реализация сред и экспериментов;
- Gymnasium — пространства наблюдений и действий;
- Ray RLlib — многоагентный PPO;
- PyTorch — нейронная сеть actor-critic.

Shared-policy схема:

- оба игрока используют одну обучаемую политику;
- наблюдение строится относительно текущего игрока;
- для симметричных игр уменьшается число обучаемых параметров;
- policy mapping задаёт текущего противника.

Идея реализации: среда возвращает observation, action mask, reward и признак завершения партии.

Рабочий процесс обучения

Основные этапы:

- 1 инициализация main policy;
- 2 выбор opponent strategies;
- 3 сбор траекторий env runners;
- 4 применение action mask к logits;
- 5 обновление PPO learner;
- 6 периодическая оценка и сохранение checkpoint.

Пул противников:

- random policy;
- minimax policy для Tic-Tac-Toe;
- исторические версии main policy;
- несимметричная выборка ролей.

Причина: второй игрок чаще ошибается в защитных позициях, поэтому такие партии чаще попадают в обучение.

Tic-Tac-Toe: среда и награда

Среда

- поле 3×3 ;
- 9 дискретных действий;
- наблюдение относительно текущего игрока;
- состояние кодируется значениями 0, 1, 2.

$$b_i \in \{0, 1, 2\}, \quad i = 1, \dots, 9.$$

Reward sweep

$$r_{\text{draw}} \in \{0, 0.2, 0.5\}.$$

- победа: +1;
- поражение: -1;
- ничья: 0, 0.2 или 0.5;
- цель оценки: доля не проигранных партий.

Параметры финальной серии экспериментов

Параметр	Значение
Алгоритм	PPO
Схема политики	shared policy для обоих игроков
Вход модели	18 признаков после разделения каналов доски
Противники	random, minimax, исторические политики
Основная серия	500 итераций, 3 независимых запуска для каждого r_{draw}
Дополнительная проверка	1000 итераций, 1 запуск для каждого r_{draw}
Batch / minibatch	4000 шагов / 256
Learning rate	10^{-4}
Discount factor	0.99
Финальная оценка	1000 партий против каждого противника



Результаты после 500 итераций

r_{draw}	Random W/D/L	Random win	Minimax W/D/L	Minimax non-loss	P2 non-loss
0.0	838.0/137.3/24.7	83.80%	0.0/955.7/44.3	95.57%	91.13%
0.2	784.3/184.0/31.7	78.43%	0.0/942.3/57.7	94.23%	88.47%
0.5	730.0/242.3/27.7	73.00%	0.0/952.0/48.0	95.20%	90.40%

Главный результат: лучшая средняя доля не проигранных партий против minimax получена при $r_{\text{draw}} = 0$: 95.57% в целом и 91.13% для второго игрока.

Наблюдение: увеличение награды за ничью не даёт монотонного улучшения.

Влияние награды за ничью




Non-loss rate против minimax после 500 итераций.

Сравнение 500 и 1000 итераций.

Вывод: простое увеличение числа итераций также не гарантирует улучшения стратегии.


Динамика оценки против minimax




Что видно:

- первый игрок стабильно не проигрывает;
- основная нестабильность связана со вторым игроком;
- валидационная оценка важнее, чем число итераций само по себе.

Распределение исходов




Против minimax побед нет: качество определяется ничьими и поражениями.



Против random виден компромисс между осторожностью и win rate.

Разделение результатов по ролям




Ключевая проблема:

- против `minimax` первый игрок не проигрывает;
- поражения возникают при игре вторым;
- модель иногда не блокирует немедленную угрозу.

Причина: PPO оптимизирует ожидаемую награду, а не `minimax`-критерий наихудшего случая.

Компромисс между защитой и победами



Интерпретация:

- большая награда за ничью делает стратегию осторожнее;
- при $r_{\text{draw}} = 0.5$ растёт число ничьих против random;
- win rate против слабого противника снижается.

Следствие: терминальная награда за ничью не заменяет локальную тактическую защиту.

Промежуточные выводы

- ❶ Реализована многоагентная схема обучения PPO для пошаговой игры.
- ❷ Маска допустимых действий корректно ограничивает пространство ходов.
- ❸ Tic-Tac-Toe подтвердил работоспособность среды и training workflow.
- ❹ Влияние награды за ничью оказалось немонотонным.
- ❺ Лучший средний результат против minimax после 500 итераций:

95.57% не проигранных партий.

- ❻ Основная слабость PPO-стратегии — игра вторым игроком в критических защитных позициях.

Следующий этап: перенести ту же методологию на Einstein Würfelt Nicht!, где появляется случайный бросок кубика.

Спасибо за внимание!